

인공지능수학 개론

(저자 김종락)

(임시적인) 목록

I. 선형대수와 인공지능

1. 파이썬 소개: 수식 중심으로
2. 선형대수 기초
 - 2.1 실습
3. 행렬의 연산 및 역행렬
 - 3.1 실습
4. 벡터와 공간, 행렬과 사상
 - 4.1 실습
5. 고윳값, 고유벡터
 - 5.1 실습

II. 미적분학과 인공지능

6. 미분과 적분
 - 6.1 실습
7. 편미분과 경사 하강법
 - 7.1 실습

III. 확률과 통계와 관련된 인공지능

8. 조건부 확률과 베이즈 정리
 - 8.1 실습
9. 상관분석과 분산 분석
 - 9.1 실습

IV. 머신러닝과 딥러닝과의 연계

10. 머신러닝 소개
 - 10.1 실습
11. 딥러닝 소개
 - 11.1 실습

Chapter 4. 벡터와 공간, 행렬과 사상

벡터는 선형대수에서 행렬만큼 중요한 주제이다. n 차원 벡터는 보통 $a = (a_1, a_2, \dots, a_n)$ 로 표현된다. 우리가 알고 있는 실수는 1차원 벡터, 평면 위의 좌표는 2차원 벡터, 공간 위의 좌표는 3차원 벡터로 생각할 수 있다. 시간을 표현하여 3차원 위치를 나타낸다면, 4차원 벡터가 필요할 것이다. 하나의 데이터 혹은 샘플은 3차원 이상의 성분으로 이루어져 있다. 이때 각 성분을 피쳐(feature)라고도 한다. 따라서 데이터 분석을 한다는 것은 여러 개의 벡터들을 하나의 공통 알고리즘으로 이해하고자 한다는 것이다.

벡터들로 이루어진 집합이 벡터의 합과 스칼라 곱에 닫혀있을 때 이 집합 V 을 **벡터 공간**이라고 한다. 두 개의 벡터 공간 V, W 가 있을 때 이 두 개를 연결하는 함수 map 를 **선형 변환**(linear transformation)이라고 한다. 이 선형 변환이 행렬로 표현된다는 것은 중요한 사실이다. 따라서 행렬은 단순히 격자로 이루어진 배열이 아니고 함수로도 볼 수 있다. 왜냐하면, $m \times n$ 행렬 A 에다가 n 차원 (열)벡터 x 를 곱하면 Ax 는 m 차원 벡터가 된다.

이 장에서는 여러 개념들을 소개하고 서로 어떻게 연결되는지 살펴본다.

■ 벡터와 벡터공간

● 벡터의 합과 차

$u = (u_1, \dots, u_n), v = (v_1, \dots, v_n)$ 라고 할 때

합은 $u + v = (u_1 + v_1, \dots, u_n + v_n)$, 차는 $u - v = (u_1 - v_1, \dots, u_n - v_n)$ 로 표현된다.

● 벡터의 스칼라 곱

α 가 스칼라이고 $u = (u_1, \dots, u_n)$ 라고 할 때

스칼라 곱은 $\alpha u = (\alpha u_1, \dots, \alpha u_n)$ 로 표현된다.

- 벡터의 차는 $u - v = u + (-1)v$ 이므로 합과 스칼라 곱만 있으면 된다.

● 벡터 공간

V 를 공집합이 아니라고 하고 u, v, w 를 V 에 속하는 n 차원 벡터라고 하자.

α, β 가 스칼라라고 하자. 보통 스칼라는 실수 집합 R 혹은 복소수 집합 C 를 의미하나, 일반적으로는 체(field)에서 성립한다. 그러면 다음이 성립하면

- (1) $u, v \in V$ 이면, $u + v \in V$ 이다.
- (2) $\alpha u \in V$
- (3) $u + v = v + u$
- (4) $u + (v + w) = (u + v) + w$
- (5) $u + 0 = u$ 인 영벡터 0 가 V 에 단 하나 존재한다.
- (6) V 의 모든 벡터 u 에 대해,
 $u + (-u) = 0$ 를 만족하는 $-u$ 가 존재한다.
- (7) $\alpha(u + v) = \alpha u + \alpha v$
- (8) $(\alpha + \beta)u = \alpha u + \beta u$
- (9) $\alpha(\beta u) = (\alpha\beta)u$
- (10) $1u = u$

이것을 만족하는 집합을 **벡터공간(vector space)**라고 한다. 이 원소들을 벡터라고 한다.

(1), (4), (5), (6)을 만족하는 것을 군(group)이라고 한다. (3)까지 만족할 때 이 군을 가환군(abelian group)이라고 한다.

● 벡터 공간의 예

R^n = n 차원 실수 벡터들로 이루어진 집합

R^n 의 부분 공간 = R^n 의 부분집합으로서 그 자체가 벡터 공간을 이루는 집합.

- (예) In R^2 에서 $S = \{(x, y) | x + y = 0\}$ 인 부분집합을 생각한다. S 가 벡터공간인가?

Yes

$x + y = 0$ 은 $y = -x$ 와 동치. 즉 원점을 지나고 기울기가 -1인 직선을 의미한다. 따라서 S 의 원소는 $(x, -x)$ 형태이다. $(x_1, -x_1) + (x_2, -x_2) = (x_1 + x_2, -(x_1 + x_2)) \in S$ 이고 $a(x_1, -x_1) = (ax_1, -ax_1) \in S$. 또한 $0 = (0, 0) = (0, -0)$ 이므로 S 에 있다. $(x, -x)$ 의 역원은 $-(x_1, -x_1) = (-x_1, x_1) = (-x_1, -(-x_1)) \in S$. 따라서 S 는 벡터공간이 된다.

- In R^2 에서 $T = \{(x, y) | x + y = 1\}$ 인 부분집합을 생각한다. T 가 벡터공간인가?

No

왜냐하면 $0 = (0, 0)$ 이 T 에 들어가 있지 않기 때문에.

- 실제로는 R^2 의 부분 공간은 $\{0\}$, 원점을 지나는 직선들, R^2 뿐이다.

P_n = 차수(degree)가 최대 n 인 실수 계수를 갖는 다항식의 모임(벡터공간)

$$= \{a_0 + a_1x + a_2x^2 + \dots + a_nx^n | a_i \in R \forall i\}$$

$$= \text{span}\{1, x, x^2, \dots, x^n\}$$

$$= \langle 1, x, x^2, \dots, x^n \rangle$$

따라서 차원 $\dim P_n = n+1$ 이라고 한다.

$M_{m \times n}(R)$ = 실수 위에서 정의된 크기가 $m \times n$ 인 행렬들의 모임(벡터공간)

(두 행렬의 합과 스칼라 곱이 정의되어 있기 때문)

- 만약 행렬의 곱셈까지 생각한다면 $M_{m \times n}(R)$ 은 환(ring)이라는 수학적 구조가 된다.

자세한 내용은 생략.

● 부분 공간의 정의

벡터공간 V 의 부분집합 S 로서, S 는 V 의 연산을 그대로 이용하면서 자신이 벡터공간이 될 때, S 를 부분 공간(subspace)이라고 한다.

- 부분공간 테스트(subspace test)

S 가 V 의 부분공간의 필요충분 조건은

(i) $0 \in S$

(ii) $x, y \in S$ 이면 $x+y \in S$

(iii) $x \in S$ 일 때, $\alpha x \in S \forall \alpha$

● 선형결합(linear combination)

$S=\{v_1, \dots, v_k\}$ 이라고 할 때, $a_1v_1 + \dots + a_kv_k$ 를 선형결합이라고 한다.

● 선형종속(linearly dependent)와 선형독립(linearly independent)

벡터공간 V 의 부분집합 $S=\{v_1, \dots, v_k\}$ 가 linearly independent라는 말은

$a_1v_1 + \dots + a_kv_k = 0$ 을 성립하는 경우는 $a_i = 0 \forall i$ 뿐이다. 그 이외의 경우를 linearly dependent라고 한다. 즉 $a_1v_1 + \dots + a_kv_k = 0$ 을 만족하는 영이 아닌 a_i 가 존재한다.

● 예제

In R^3 , $S = \{e_1 = (1,0,0), e_2 = (0,1,0), e_3 = (0,0,1)\}$ 는 linearly independent하다. 왜냐

하면 $a_1e_1 + a_2e_2 + a_3e_3 = 0, i.e.,$

$$(a_1, a_2, a_3) = 0, i.e.,$$

$$a_1 = 0 = a_2 = a_3$$

● 생성 집합(spanning set)

V 의 임의의 원소를 주어진 집합 S 의 선형결합으로 표현가능할 때 S 가 V 를 span(생성, generate)한다고 한다.

기호로는 $V=\text{span}(S)$

● 기저(basis)

V 의 부분집합 S 가 V 를 생성하고 동시에 S 가 linearly independent할 때 S 를 V 의 basis라고 한다.

● 표준기저(standard basis)

R^n 의 표준기저는 $\{e_i = (0,0, \dots, 1, 0, \dots, 0) \mid i=1, \dots, n\}$ 이다. 직교 좌표계의 근본을 이루는 집합이 바로 표준기저였다.

● 정리

벡터공간 V 의 기저가 주어져 있을 때, V 의 임의의 원소는 기저들의 선형결합으로 유일하게 표현된다.

● 차원(dimension of a vector space)

● 벡터의 크기(norm)

● 벡터의 내적

$$(1) \quad \|u\| \geq 0$$

$$(2) \quad \|\alpha u\| = |\alpha| \|u\|$$

$$(3) \quad \|u + v\| \leq \|u\| + \|v\|$$

$$(4) \quad \|u\| = 0 \text{인 경우는 } u = 0 \text{일 때뿐이다.}$$

● 내적의 성질

$$(1) \quad x \cdot y = y \cdot x$$

$$(2) \quad (x + y) \cdot z = x \cdot z + y \cdot z$$

$$(3) \quad z \cdot (x + y) = z \cdot x + z \cdot y$$

$$(4) \quad c(x \cdot y) = (cx) \cdot y = x \cdot (cy)$$

$$(5) \quad x \cdot x = \|x\|^2 \geq 0$$

$$(6) \quad x = 0 \text{일 때만 } x \cdot x = 0 \text{이다.}$$

● 내적과 사잇각

$$\mathbf{x} \cdot \mathbf{y} = \|\mathbf{x}\| \|\mathbf{y}\| \cos \theta$$

● 코시-슈바르츠 부등식 Cauchy-Schwarz inequality

$$|\mathbf{x} \cdot \mathbf{y}| \leq \|\mathbf{x}\| \|\mathbf{y}\|$$

● 삼각부등식 Triangle inequality

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$$

● 직교 orthogonal

$$\mathbf{x} \cdot \mathbf{y} = 0$$

● 피타고라스의 정리 Pythagorean theorem

R^n 에 있는 임의의 두 벡터 \mathbf{x}, \mathbf{y} 가 직교하는 것과 동치는

$$\|\mathbf{x} + \mathbf{y}\|^2 = \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2$$

(증명) $\|\mathbf{x} + \mathbf{y}\|^2 = (\mathbf{x} + \mathbf{y}) \cdot (\mathbf{x} + \mathbf{y})$ 를 계산해 본다.

● 정사영

R^n 에 있는 임의의 두 벡터 x, y 에 대하여, 벡터 x 의 y 방향의 벡터를 x 의 y 위로의 정사영(orthogonal projection)이라고 한다. 영어로는 projection of x onto y 라고 읽고


$$\text{proj}_y x$$

라고 쓴다. 기하학적 의미는?

● 정사영을 dot product로 표현하면 다음과 같다.

$$\text{Proj}_x^y = \frac{x \cdot y}{y \cdot y} y$$

(증명)



$u = \frac{y}{\|y\|}$ 라고 하자. 즉 u 는 y 방향의 단위벡터. 그러면

$\text{Proj}_x^y = ku$ (단, k 는 어떤 실수). 정사영의 정의에 의하여

$(x - ku) \cdot ku = 0$ 이 된다. k 관하여 풀면

$k = \frac{x \cdot u}{u \cdot u}$ 가 된다. 따라서

$$\text{Proj}_x^y = ku = \frac{x \cdot u}{u \cdot u} u = \frac{x \cdot (\frac{y}{\|y\|})}{\frac{y}{\|y\|} \cdot \frac{y}{\|y\|}} \frac{y}{\|y\|} = \frac{x \cdot y}{y \cdot y} y$$

가 된다.

● 예제

벡터 $x = (1, 1)$ 의 벡터 $y = (2, 0)$ 으로의 정사영을 구하시오.

- 정답은 (1,0)

● (정의) 내적공간 inner product space

실벡터공간 V 에 속하는 임의의 두 벡터 x, y 에 대하여 다음의 세가지 조건을 만족하는 함수를 x 와 y 의 내적이라고 하고 $\langle x, y \rangle$ 또는 $x \cdot y$ 라고도 쓴다.

- (1) 임의의 $x \in V$ 에 대해, $\langle x, x \rangle \geq 0$ 이다. 특히, $x = 0$ 일 때만 $\langle x, x \rangle = 0$ 이다.
- (2) 임의의 $x, y \in V$ 에 대해, $\langle x, y \rangle = \langle y, x \rangle$ 이다.
- (3) 임의의 $x, y, z \in V$, 스칼라 α, β 에 대해, $\langle \alpha x + \beta y, z \rangle = \alpha \langle x, z \rangle + \beta \langle y, z \rangle$ 이다.

● (예제) $V = R^n$ 라고 할 때 $x = (x_1, \dots, x_n), y = (y_1, \dots, y_n)$ 에 대하여 내적공간을

$x \cdot y = \sum_{i=1}^n x_i y_i$ 으로 정의한다. 이것을 보통의 내적(usual inner product) 또는 유클리디언 내적(Euclidean inner product)이라고 한다.

● (예제) $V = M_{m \times n}(R)$ =실수 위에서 정의된 $m \times n$ 행렬의 모임이라고 할 때 $A, B \in M_{m \times n}(R)$ 에 대하여 내적공간을 아래와 같이 정의할 수 있다.

$$\langle A, B \rangle = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ij}$$

이 내적의 의미는?

● (예제) 구간 $[0,1]$ 위에서 정의된 연속 함수 $f(x), g(x)$ 들의 집합은 벡터공간 V 을 이룬다. 이러한 $f(x), g(x)$ 에 대하여 아래와 같이 내적공간을 정의할 수 있다.

$$\langle f, g \rangle = \int_0^1 f(x) g(x) dx$$

● (정의) 벡터공간 V 가 주어지고, 임의의 v 에 대하여 실수 값 $\|v\|$ 가 정의되고 다음을 만족할 때, 이 벡터공간을 노름공간 normed space라고 한다.

- (1) 임의의 $v \in V$ 에 대해 $\|v\| \geq 0$ 이다. 특히, $v = 0$ 일 때만 $\|v\| = 0$ 이다.
- (2) 임의의 $v \in V$ 와 스칼라 α 에 대해, $\|\alpha v\| = |\alpha| \|v\|$ 이다.
- (3) 임의의 $u, v \in V$ 에 대해, $\|u + v\| \leq \|u\| + \|v\|$ 이다.

● (예제) V 를 내적이 정의된 실수 벡터 공간이라고 하고 $\|x\| = \sqrt{\langle x, x \rangle}$ 라고 하면 V 는 노름공간이 된다.

● (예제) 그러나 R^n 이 $\|x\|_\infty = \max\{|x_1|, \dots, |x_n|\}$ 는 노름을 정의하지만 내적을 정의할 수는 없다. 따라서 내적공간은 노름공간이 되나 그 역은 참이 아니다.

■ 벡터와 미분

이제 벡터와 미분을 연결해 보자. 즉 다변수함수에 대하여 벡터에 관하여 미분을 할 수가 있다.

● (정의) 다변수함수 $f(x_1, x_2, \dots, x_n)$ 에 대하여 벡터 $x = (x_1, x_2, \dots, x_n)$ 에 대한 미분의

정의는 $\nabla f = \frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}$ 인 벡터이고 f 의 그래디언트gradient라고 한다.

● (예제)

$f(x, y, z) = xyz$ 라고 할 때 ∇f 를 구하시오.

- (정의) 벡터함수 $F(x_1, \dots, x_n) = \begin{bmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_n(x_1, \dots, x_n) \end{bmatrix}$ 에 대하여 각 변수 x_i 에 대한 F 의 미

분은 아래와 같다.

$$\frac{\partial F}{\partial x_i} = \begin{bmatrix} \frac{\partial f_1}{\partial x_i} & \frac{\partial f_2}{\partial x_i} & \dots & \frac{\partial f_n}{\partial x_i} \end{bmatrix}$$

이다. $x = (x_1, \dots, x_n)$ 이라고 할 때

$$\frac{\partial F}{\partial x} = \begin{bmatrix} \frac{\partial F}{\partial x_1} \\ \frac{\partial F}{\partial x_2} \\ \vdots \\ \frac{\partial F}{\partial x_n} \end{bmatrix} \text{를 자코비안 행렬 Jacobian matrix라고 하고 } J_F \text{라고 쓴다.}$$

- (정의) 다변수함수 $f(x_1, x_2, \dots, x_n)$ 에 대하여 벡터 $x = (x_1, x_2, \dots, x_n)$ 에 대한 2차 미분 $\frac{\partial^2 f}{\partial x^2}$ 을 헤시안 행렬 Hessian matrix라고 하고 $H(f)$ 라고 쓴다.

$$\frac{\partial^2 f}{\partial x^2} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \dots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \dots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

- (정의) 다변수함수 $f(x_1, x_2, \dots, x_n)$ 의 라플라시안 Laplacian은

$$\nabla^2 f = \frac{\partial^2 f}{\partial x_1^2} + \dots + \frac{\partial^2 f}{\partial x_n^2}$$

이다.

- (예제) $f(x, y) = x^3 + 2x + y^2$ 이라고 할 때 $\nabla^2 f$ 를 구하시오.

x 에 대하여 f 를 두 번 미분하면 $6x$ 가 된다. y 에 대하여 f 를 두 번 미분하면 2 가 된다. 따라서 $\nabla^2 f = 6x + 2$ 가 된다.