

# 인공지능수학 개론

(저자 김종락)

(임시적인) 목록

## I. 선형대수와 인공지능

1. 파이썬 소개: 수식 중심으로
2. 선형대수 기초
  - 2.1 실습
3. 행렬의 연산 및 역행렬
  - 3.1 실습
4. 벡터와 공간, 행렬과 사상
  - 4.1 실습
5. 선형변환, 고윳값, 고유벡터
  - 5.1 실습

## II. 미적분학과 인공지능

6. 미분과 적분
  - 6.1 실습
7. 편미분과 경사 하강법
  - 7.1 실습

## III. 확률과 통계와 관련된 인공지능

8. 조건부 확률과 베이즈 정리
  - 8.1 실습
9. 상관분석과 분산 분석
  - 9.1 실습

## IV. 머신러닝과 딥러닝과의 연계

10. 머신러닝 소개
  - 10.1 실습
11. 딥러닝 소개
  - 11.1 실습

## Chapter 5. 선형변환, 고윳값, 고유벡터

두 개의 벡터 공간  $V, W$  가 주어졌을 때, 이 공간들 사이의 관계를 어떻게 이해할 수 있을까? 두 벡터 공간이 본질적으로 같다는 것은 무슨 뜻일까? 또한 두 벡터 공간이 유사하다는 것은 무슨 뜻일까? 이러한 질문에 답하기 위해선 선형변환의 개념이 필요하다.

선형변환은 하나의 벡터 공간  $V$ 에서 자신 또는 다른 벡터 공간  $W$  가는 함수  $L$ 로서  $V$ 의 연산들이 그대로 보존되는 성질을 갖고 있다. 따라서  $V$ 의 원소들 사이의 연산 값이  $L$ 에 의하여 이동된 원소들 사이의 연산 값과 같다. 예를 들어, 거울은 우리의 이미지를 좌우가 바뀐 상태로 그대로 반영하고 있다. 망원경이나 현미경은 작은 물체를 크게 확대하지만 그 모양을 그대로 유지하고 있다. 이러한 성질을 수학적으로 설명할 수가 있다.

고윳값은 선형대수의 중에 특별한 성질을 갖고 있다. 주어진 선형변환  $L$ 이 적당한  $v \in V$ 의 원소를 스칼라 곱으로 변환시키는 경우를 말한다. 즉  $L(v) = \lambda v$ 을 만족한다. 이때 나오는  $\lambda$ 를 고윳값이라고 하고  $v$ 를 고유벡터라고 한다. 고윳값과 고유벡터는 선형변환의 특징을 반영하는 중요한 값들이다. 머신러닝에서 등장하는 주성분분석(PCA)은 고윳값의 크기가 큰 순서로 나열한 후 그에 대응하는 고유벡터들을 새로운 축으로 변환하여 기존 데이터를 읽어 들이는 방법이다. 이 방법은 차원의 저주(curse of dimension)을 부분적으로 해결한 것으로 볼 수 있다.

이 장에서는 여러 개념들을 소개하고 서로 어떻게 연결되는지 살펴본다.

## ■ 선형변환

### ● (정의)

벡터공간  $V$ 에서 벡터공간  $W$ 로 가는 함수  $L: V \rightarrow W$ 가

(1) 모든  $u, v \in V$ 에 대하여  $L(u+v) = L(u) + L(v)$

(2) 모든  $v \in V$ 와 스칼라  $c$ 에 대하여  $L(cv) = cL(v)$

을 만족할 때 이  $L$ 을 선형변환(linear transformation, linear map)이라고 한다.

(그림)

● (예제)  $V = \mathbb{R}^n$ 이라고 하고  $L(x) = 3x$ 라고 할 때  $L$ 은 선형변환이다.

(증명)

● (예제) 일반적으로  $V = \mathbb{R}^n$ 이라고 하고  $L(x) = ax$  (단,  $a$ 는 실수인 상수)라고 할 때  $L$ 은 선형변환이다. 만약  $a = 0$ 이면  $L(x) = 0$ 이고 이를 자명변환(trivial map)이라고 한다.

(증명)

● (예제) 일반적으로  $V = \mathbb{R}^n$ 이라고 하고  $L(x) = ax + b$  (단  $a, b$ 는 상수이며  $b \neq 0$ )일 때  $L$ 은 선형변환이 아니다.

(증명)

● (질문) 선형변환은 어떻게 만들면 될까?

$V = \mathbb{R}^2$ 라고 하고  $L(x) = 3x$ 인 선형변환을 좀 더 다르게 표현해 보자.

$$L \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 3 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 3x_1 \\ 3x_2 \end{pmatrix} = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

따라서 스칼라로 표현된 선형변환을 대각행렬로 표현할 수 있었다. 여기에 영감을 받아 대각행렬대신 임의의 행렬로 대신해도 과연 선형변환이 될까?

● (정리) 벡터공간  $V = R^n$ 이라고 하고  $W = R^m$ 이라고 하자. 행렬  $A$ 를 실수 위에서 정의된  $m \times n$  행렬이라고 하자. 그러면  $L(v) = Av$ 라고 정의된 함수가 선형변환이 된다. (단 여기서  $v$ 는 열벡터로 이해한다.)  
(증명)

놀라운 사실은  $V = R^n$ 에서  $W = R^m$ 로 가는 임의의 선형변환은 행렬로 표현가능하다는 것이다.

● (중요 정리) 만약  $L: R^n \rightarrow R^m$ 이 선형변환이라고 하면  $L(v) = Av$ 를 만족하는  $m \times n$  행렬  $A$ 가 존재한다.

(증명) 임의의 벡터  $v \in V$ 는  $v = v_1 e_1 + \dots + v_n e_n$  (단  $\{e_1, \dots, e_n\}$ 는 표준기저)로 표현할 수 있다.

$$\begin{aligned} L(v) &= v_1 L(e_1) + \dots + v_n L(e_n) \\ &= [L(e_1) \dots L(e_n)] \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix} \\ &= Av \end{aligned}$$

● (정의) 위 정리에 나오는  $A$ 를 선형변환  $L$ 의 표준행렬(Standard matrix)라고 한다.

● (예제)

- 회전변환 rotation

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}, \quad \begin{aligned} x_2 &= x_1 \cos \theta - y_1 \sin \theta \\ y_2 &= x_1 \sin \theta + y_1 \cos \theta \end{aligned}$$

- 반사변환 reflection

1.  $x$ 축을 기준으로 반사하는 선형변환이 아래와 같을 때

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}, \quad \begin{matrix} x_2 = x_1 \\ y_2 = -y_1 \end{matrix}$$

표준행렬  $A$ 를 구하시오.

2.  $y$ 축을 기준으로 반사하는 선형변환과 그의 표준행렬을  $B$ 를 구하시오.

선형변환을 합성해도 선형변환이 된다.

● (정리) 벡터공간  $U, V, W$ 에 대하여 두 개의 선형변환  $L_1: U \rightarrow V, L_2: V \rightarrow W$ 에 대하여 그의 합성인  $L_2 \circ L_1: U \rightarrow W$ 도 선형변환이 된다.

(증명)

위 합성 선형변환을 행렬로 표현하면 어떤 것이 될까?

● (정리) 두 개의 선형변환  $L_1: U \rightarrow V, L_2: V \rightarrow W$ 의 표준행렬을 각각  $A_1, A_2$ 라고 할 때,  $L_2 \circ L_1: U \rightarrow W$ 의 표준행렬은  $A_2 A_1$ 이 된다.

(증명)

실수에서 곱셈의 항등원 1이 있듯이 항등원의 역할을 하는 선형변환이 있다.

● (정의) 벡터공간  $V$ 에 대하여  $I_V: V \rightarrow V, I_V(v) = v$ 를 만족할 때,  $I_V$ 를 항등 선형변환(identity linear transformation)이라고 한다.

실수  $a$ 의 곱셈에 대한 역원  $a^{-1}$ 이 있듯이 역변환을 정의할 수 있다.

● (정의)

선형변환  $L_1: U \rightarrow V$ 과  $L_2: V \rightarrow U$ 에 대하여  $L_2 \circ L_1 = I_U, L_1 \circ L_2 = I_V$ 를 만족할 때  $L_2$ 를  $L_1$ 의 역변환(inverse linear transformation)이라고 하고  $L_2 = L_1^{-1}$ 이라고 쓴다.

만일  $U = V$ 이고 선형변환  $L: V \rightarrow V$ 의 역변환이 존재하고 표준행렬을  $A$ 라고 하면

역변환  $L^{-1}$ 의 표준행렬은  $A^{-1}$ 이 된다. 선형변환  $L: V \rightarrow V$ 을 선형연산자(linear operator)라고 한다.

● (정의) 선형연산자  $L: V \rightarrow V$ 가 주어졌을 때 모든  $u, v \in V$ 에 대하여  $L(u) \cdot L(v) = u \cdot v$ 을 만족할 때  $L$ 를 직교연산자(linear operator)라고 한다.

● (정리) 선형연산자  $L: R^n \rightarrow R^n$ 가 주어졌을 때,  
모든  $u \in R^n$ 에 대하여  $\|L(u)\| = \|u\|$ 인 필요충분 조건은 모든  $u, v \in R^n$ 에 대하여  $L(u) \cdot L(v) = u \cdot v$ 을 만족하는 것이다.

따라서 직교연산자를 노름보존 선형연산자(norm-preserving linear operator)라고 한다.

## ■ 선형변환의 부분공간과 랭크

● (정의)  $A$ 를  $m \times n$ 행렬이라고 할 때 다음과 같이 정의한다.

- 열공간(column space)
- 행공간(row space)
- 영공간(null space or kernel)

$Ax =$  a linear comb. of the columns of  $A$

$\in \text{Col}(A) = \text{Span}(\text{columns of } A)$   
subspace of  $\mathbb{R}^m$

$\text{Row}(A) = \text{Span}(\text{rows of } A)$  행공간

$L(x) = Ax$ 라고 하자.

$\text{Nul}(A) = \text{Kernel}(L)$

$= \{x \in \mathbb{R}^n \mid L(x) = 0 \text{ 즉, } Ax = 0\}$

● (정의)  $A$ 를  $m \times n$ 행렬이라고 할 때  $A$ 의 계수(rank)를  $\text{rank}(A)$ 라고 쓰고

$\text{rank}(A) = \dim(\text{Col}(A))$

로 계산된다.

● (예제)

- (정리) 영공간의 정의역  $\mathbb{R}^n$ 의 부분공간이다.  
(증명)

$\text{Nul}(A)$  is a subspace of  $\mathbb{R}^n$ ,

(  $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$  is a linear transform. )

(pf.  $0 \in \text{Nul}(A)$  since  $A0 = 0$ .)

$$\begin{aligned} \cdot \text{ Let } x, y \in \text{Nul}(A). \quad A(x+y) &= \underbrace{Ax}_0 + \underbrace{Ay}_0 = 0 \\ x+y &\in \text{Nul}(A) \end{aligned}$$

$$\begin{aligned} \cdot \text{ Let } x \in \text{Nul}(A). \quad A(cx) &= c \underbrace{Ax}_0 = 0. \\ \therefore cx &\in \text{Nul}(A). \end{aligned}$$

따라서 영공간을 구하기 위해서는  $Ax=0$ 의 해집합을 구하면 된다.

- (정의) 행렬  $A$ 의 영공간의 차원을 퇴화차수(nullity)라고 한다. 즉  $\text{nullity}(A) = \dim(\text{Nul}(A))$ .



● (정리) (차원의 정리 또는 랭크 정리)

$m \times n$  행렬  $A$ 에 대하여

$$\dim(\text{Col}(A)) + \dim(\text{Nul}(A)) = n$$

이 성립한다.

(증명)

$$\begin{aligned} \text{pivot의 개수} &= \dim(\text{Row}(A)) & A = \begin{bmatrix} \text{---} & 1 & \text{---} \\ \text{---} & 0 & \text{---} \\ \text{---} & 0 & \text{---} \\ \text{---} & 0 & \text{---} \end{bmatrix} \\ \parallel \\ \dim(\text{Col}(A)) &= \dim(\text{Row}(A)) & \text{Col}(A) = \{ Ax \mid x \in \mathbb{R}^n \} \\ & & Ax = b \text{를 만족하는 } x \text{가 존재,} \\ & & \exists x \in \mathbb{R}^n \text{ s.t. } Ax = b. \\ & \Leftrightarrow & \text{Col}(B) \quad \underline{Bx = b'} \quad (B = \text{rref}(A)) \\ & & A \sim B. \end{aligned}$$

## ■ 고윳값과 고유벡터

● (정의)  $n$ 차 정방행렬  $A$ 에 대하여  $Ax = \lambda x$ 를 만족하는  $x \neq 0$ 가 존재할 때  $\lambda$ 를  $A$ 의 고윳값(eigenvalue)라고 하고  $x$ 를 고유벡터(eigenvector)라고 한다.

- 고유벡터는 영벡터가 될 수 없으나 고윳값은 0이 될 수가 있다.
- $\lambda = 0$ 과 동치는 무엇일까?
- $Ax = \lambda x$   
 $Ax - \lambda x = 0$   
 $\Leftrightarrow (\lambda I - A)x = 0$   
 $\Leftrightarrow \det(\lambda I - A) = 0$

따라서 행렬  $A$ 의 고윳값을 모두 구할 수 있다.

● (정의)  $n$ 차 정방행렬  $A$ 에 대하여  $p_A(\lambda) = \det(A - \lambda I)$ 를 특성다항식 characteristic polynomial이라고 하고  $\det(A - \lambda I) = 0$ 을  $A$ 의 특성방정식 characteristic equation이라고 한다.

-  $n$ 차 정방행렬  $A$ 이 고윳값은 없을 수도 있고 중복이 될 수도 있다. 최대  $n$ 개를 갖을 수 있다.

-  $n$ 차 정방행렬  $A$ 의 고윳값 중의 하나를  $\lambda$ 라고 하자. 그러면 이에 대응하는 고유벡터들은 벡터공간을 이룬다. 이 벡터공간을  $E_\lambda$ 라고 하고 고유공간이라고 한다. 즉

$E_\lambda = \{x \in R^n \mid Ax = \lambda x\}$ . 즉  $E_\lambda$ 는 모든 고유벡터들과 영벡터를 합한 것이다.

● (정리)  $n$ 차 정방행렬  $A$ 의 고윳값은 최대  $n$ 개다.

(증명)

- $n$ 차 정방행렬  $A$ 에 대한 특성방정식  $\det(\lambda I - A) = 0$ 은  $n$ 차 다항식
- $n$ 차 다항식은 복소수 범위에서  $n$ 개의 근을 가짐
- 동일한 고윳값이 나타나는 횟수인 중복도(multiplicity)와 복소수 근까지 고려하면,  $n$ 개의 고윳값 존재

● (정리)  $n$ 차 정방행렬  $A$ 이 가역행렬이고  $\lambda$ 이 고윳값이면  $A^{-1}$ 의 고윳값은  $\lambda^{-1}$ 이 된다.

(증명)

$$\begin{aligned} Ax = \lambda x &\Rightarrow x = \lambda A^{-1}x \\ &\Rightarrow A^{-1}x = \frac{1}{\lambda}x \end{aligned}$$

● (정리)  $n$ 차 정방행렬  $A$ 에 대하여  $n$ 개의 고윳값  $\lambda_1, \dots, \lambda_n$ 이 존재할 때 다음이 성립한다.

(1)  $\det(A) = \lambda_1 \lambda_2 \cdots \lambda_n$

(2)  $\text{tr}(A) = \lambda_1 + \lambda_2 + \cdots + \lambda_n$

(증명)  $p_A(\lambda) = |\lambda I - A|$

$$= (\lambda - \lambda_1)(\lambda - \lambda_2) \cdots (\lambda - \lambda_n)$$

$$= \lambda^n - (\lambda_1 + \lambda_2 + \cdots + \lambda_n)\lambda^{n-1} + \cdots + (-1)^n \lambda_1 \cdots \lambda_n$$

$$= \lambda^n - \text{tr}(A)\lambda^{n-1} + \cdots + (-1)^n \det(A)$$

(1)  $\lambda = 0$ 을 대입하면  $\det(A) = \lambda_1 \lambda_2 \cdots \lambda_n$ 가 성립한다.

$$\begin{aligned} (2) \quad |\lambda I - A| &= \begin{vmatrix} \lambda - a_{11} & \lambda - a_{12} & \cdots & \lambda - a_{1n} \\ \lambda - a_{21} & \lambda - a_{22} & \cdots & \lambda - a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ \lambda - a_{n1} & \lambda - a_{n2} & \cdots & \lambda - a_{nn} \end{vmatrix} \\ &= \lambda^n - (a_{11} + \cdots + a_{nn})\lambda^{n-1} + r(\lambda) \end{aligned}$$

$$(\text{단, } \deg(r(\lambda)) \leq n-2)$$

이므로  $\text{tr}(A) = \lambda_1 + \lambda_2 + \cdots + \lambda_n$ 가 성립한다.

● (정리)(케일리-해밀턴 정리 Cayley-Hamilton theorem)  $n$ 차 정방행렬  $A$ 의 특성 방정식  $p_A(\lambda) = |\lambda I - A| = \lambda^n + a_{n-1}\lambda^{n-1} + a_{n-2}\lambda^{n-2} + \cdots + a_1\lambda + a_0 = 0$ 일 때  $\lambda$ 대신에  $A$ 를 대입하면  $p_A(A) = A^n + a_{n-1}A^{n-1} + \cdots + a_1A + a_0I = O$ 을 만족한다.

(증명) Omit.

## ■ 주성분 분석(Principal Component Analysis, PCA)

- (정의)  $n$ 차원의 데이터  $\{x_1, x_2, \dots, x_k\}$ 에 대하여 평균벡터 (mean vector)는

$$m = \frac{1}{k} \sum_{i=1}^k x_i$$

로 정의된다. 공분산 행렬(covariance matrix)는

$$C = \frac{1}{k} \sum_{i=1}^k (x_i - m)(x_i - m)^T$$

로서  $n \times n$  행렬이다.  $m=0$ 이면  $C = \frac{1}{k} \sum_{i=1}^k x_i x_i^T$ 가 된다.

- (PCA) [참고, <응용이 보이는 선형대수학>]

$\{x_1, x_2, \dots, x_m\}$ 을 새로운 기저  $\{u_1, u_2, \dots, u_n\}$ 의 좌표계로 선형변환

$$x = \sum_{i=1}^n (x^\top u_i) u_i \quad u_j (j=1, 2, \dots, n) \text{는 직교하는 단위벡터}$$

$x^\top u_i = x \cdot u_i$ 는  $x$ 를  $u_i$  방향으로 정사영한 벡터의 크기에 해당

처음  $K$ 개의 기저벡터만을 사용하여  $x$ 를  $\hat{x}$ 으로 근사

$$\hat{x} = \sum_{i=1}^K (x^\top u_i) u_i$$

-  $K$ 차원으로 근사할 때 발생하는 오차를  $J$ 라고 하면 아래가 성립한다.

$$\begin{aligned}
J &= \frac{1}{n} \sum_{i=1}^n \left\| x_i - \hat{x}_i \right\|^2 = \frac{1}{n} \sum_{i=1}^n \left\| \sum_{j=1}^n (x_i^\top u_j) u_j - \sum_{j=1}^K (x_i^\top u_j) u_j \right\|^2 \\
&= \frac{1}{n} \sum_{i=1}^n \left\| \sum_{j=K+1}^n (x_i^\top u_j) u_j \right\|^2 \\
&= \frac{1}{n} \sum_{i=1}^n \sum_{j=K+1}^n (x_i^\top u_j)^2 \quad (\because x_i^\top u_j \text{는 스칼라, } u_j \text{는 단위벡터}) \\
&= \frac{1}{n} \sum_{i=1}^n \sum_{j=K+1}^n (x_i^\top u_j)^\top (x_i^\top u_j) \\
&= \frac{1}{n} \sum_{i=1}^n \sum_{j=K+1}^n u_j^\top x_i x_i^\top u_j \\
&= \sum_{j=K+1}^n u_j^\top \left( \frac{1}{n} \sum_{i=1}^n x_i x_i^\top \right) u_j \\
&= \sum_{j=K+1}^n u_j^\top C u_j \quad (\because \text{평균벡터가 영벡터이므로, } \frac{1}{n} \sum_{i=1}^n x_i x_i^\top = C)
\end{aligned}$$

한편  $u_j^\top C u_j$  값은 아래와 같이 계산하면  $\sigma_j^2$ 이 된다.

$$\begin{aligned}
u_j^\top C u_j &= u_j^\top \left( \frac{1}{n} \sum_{i=1}^n x_i x_i^\top \right) u_j = \frac{1}{n} \sum_{i=1}^n u_j^\top x_i x_i^\top u_j \\
&= \frac{1}{n} \sum_{i=1}^n (x_i^\top u_j)^\top (x_i^\top u_j) = \sigma_j^2
\end{aligned}$$

즉

$$J = \sum_{j=K+1}^n \sigma_j^2$$

- 분산을 가장 크게 하는 기저벡터  $u$ 를 찾는 문제를 풀어야 한다. 라그랑지 승수 (Lagrange multiplier)를 이용하여 다음의 문제를 해결한다.

$$u^{\top} C u \text{를 최대화하는 } u \text{를 찾으라.}$$

$$(\text{제한 조건 : } \|u\|^2 = 1)$$

$$\tilde{J} = u^{\top} C u - \lambda(u^{\top} u - 1)$$

$$C u - \lambda u = 0 \quad \Rightarrow \quad C u = \lambda u$$

$$u^{\top} C u = \lambda u^{\top} u = \lambda = \sigma^2$$

- 따라서  $C$ 로부터 고윳값의 크기가 큰 순서대로  $K$ 개의 고유벡터  $\{u_1, u_2, \dots, u_K\}$ 를 선택한다. 보통  $K=2$ 를 많이 선택한다.

-